El proceso de Poisson

Nayeli Cruz Fonseca · Licenciatura en Actuaría · Octubre de 2026

Introducción

El proceso de Poisson es, para mí, el modelo más natural para responder una pregunta muy común: **¿cuántas veces ha ocurrido algo hasta cierto momento?** Por ejemplo, cuántas llamadas recibió un conmutador, cuántos clientes llegaron a una fila o cuántos siniestros se reportaron a una aseguradora. En la clase se presenta como un caso particular de una familia más grande, los procesos de conteo, y se estudia desde varias miradas que al final dicen lo mismo.

Lo que más rescato del video es que el proceso de Poisson se puede leer de **cuatro maneras equivalentes**: como un proceso con incrementos independientes y de ley Poisson, como una cadena de Markov a tiempo continuo de puros nacimientos, como la suma de tiempos de espera exponenciales y como puntos "uniformes" repartidos en el tiempo. Cada lectura sirve para algo distinto: calcular probabilidades, construir martingalas, simular o hacer estadística.

El resumen sigue el orden de la clase: primero defino los procesos de conteo, luego el proceso de Poisson y sus distribuciones, después su generador y su relación con las cadenas de Markov, sus momentos, los tiempos de llegada, el resultado de los estadísticos de orden y, al final, los temas que siguen. Agregué algunos ejemplos numéricos propios para que cada idea quede más clara.

1. Procesos de conteo

Se trabaja sobre un espacio de probabilidad completo $(\Omega, \mathscr{F}, \mathbb{P})$ con una filtración $(\mathcal{F}_t)$, que representa la información que se va acumulando con el tiempo. Un **proceso de conteo** $\{N_t : t \geq 0\}$ cumple, para cada ω:

- **Empieza en cero:** $N_0 = 0$.
- **Toma valores enteros:** $N_t \in \mathbb{N} \cup \{0\}$.
- **Es no decreciente:** si $s \leq t$, entonces $N_s \leq N_t$.

En mis palabras: N_t **cuenta cuántos eventos han ocurrido hasta el tiempo t**. Por eso nunca baja y sólo avanza de uno en uno. Ejemplos de la clase: número de llamadas recibidas hasta t, número de clientes que llegan a una fila o número de saltos de un sistema.

1.1 Procesos de conteo más generales

La clase menciona que existen versiones más generales en las que se pide que el proceso sea:

- **Creciente y càdlàg:** continuo por la derecha y con límites por la izquierda.
- **De valores enteros** y **adaptado** a una filtración (por ejemplo, la filtración natural del proceso).
- Que pueda tener **saltos de tamaño mayor a uno**, que representan eventos simultáneos.
- Que tenga **intensidades que dependen del tiempo**, lo que da lugar a procesos no homogéneos.

Dentro de esta familia están los procesos de Poisson no homogéneos, los procesos de renovación y, en general, los procesos puntuales. La clase empieza por el caso más sencillo: el proceso de Poisson **homogéneo**.

2. Definición del proceso de Poisson homogéneo

Un proceso de Poisson homogéneo con **tasa o intensidad $\lambda > 0$** es un proceso de conteo que cumple dos condiciones para todo $0 \leq s < t$:

1. **Incrementos independientes del pasado:** el incremento $N_t - N_s$ es independiente de toda la información de la trayectoria hasta el tiempo s.
2. **Incrementos con ley Poisson:** $N_t - N_s \sim \text{Poisson}(\lambda(t-s))$.

$$\mathbb{P}(N_t - N_s = k) = e^{-\lambda(t-s)} \frac{[\lambda(t-s)]^k}{k!}, \quad k = 0, 1, 2, \ldots$$

En palabras: $\mathbb{P}(k \text{ eventos entre } s \text{ y } t) = e^{-(tasa)(longitud\ del\ intervalo)} \times \frac{[(tasa)(longitud\ del\ intervalo)]^k}{k!}$

Un detalle que la clase subraya: el término t − s es la **medida de Lebesgue** (la longitud) del intervalo (s, t]. Es decir, el parámetro de la Poisson es la tasa multiplicada por la longitud del intervalo. Por eso se dice que la intensidad actúa como una **homotecia** (un "estiramiento") de la medida de Lebesgue: el número esperado de eventos en un intervalo sólo depende de qué tan largo es, no de dónde está.

2.1 Consecuencias: distribuciones marginales y finito-dimensionales

Si tomo s = 0 y uso que $N_0 = 0$, obtengo la ley de N_t para cada t ≥ 0:

$$N_t \sim Poisson(\lambda t), \quad \mathbb{P}(N_t = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}, \quad n = 0, 1, 2, \ldots$$

Además, para cualquier partición $0 = t_0 < t_1 < \ldots < t_k$ el vector de incrementos

$$\left(N_{t_1} - N_{t_0}, N_{t_2} - N_{t_1}, \ldots, N_{t_k} - N_{t_{k-1}}\right)$$

tiene **componentes independientes** y cada una es Poisson($\lambda(t_i - t_{i-1})$). Con esto quedan determinadas todas las distribuciones finito-dimensionales del proceso: "está todo controlado", como se dice en la clase. Los dos rasgos clave son:

- **Independencia entre intervalos ajenos:** lo que pasa en intervalos que no se traslapan es independiente.
- **Ley Poisson en cada incremento**, con parámetro igual a λ por la longitud del intervalo.

Ejemplo propio. Si llegan clientes con λ = 2 por hora, el número de llegadas en 3 horas es $N_3 \sim$ Poisson(6). La probabilidad de que lleguen exactamente 4 es:

$$\mathbb{P}(N_3 = 4) = e^{-6}\frac{6^4}{4!} = \frac{1296}{24}e^{-6} = 54e^{-6} \approx 0.1339$$

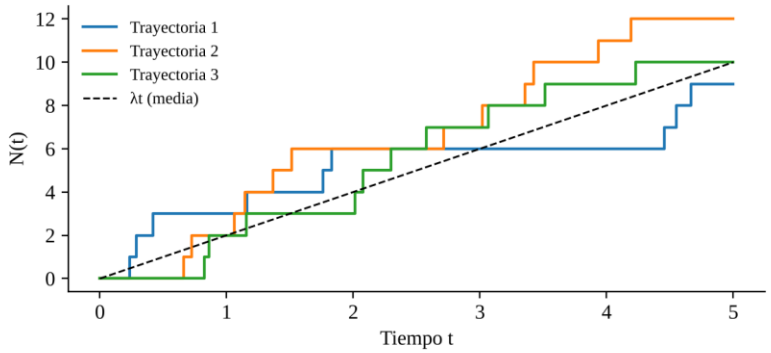


Figura 1. Tres trayectorias simuladas con λ = 2. El proceso sube de uno en uno y crece en promedio como λt.

3. El generador infinitesimal y la lectura como cadena de Markov

3.1 Definición del generador

Para una función acotada $f : \mathbb{N} \to \mathbb{R}$, la clase define el **generador** del proceso como el límite de la variación esperada por unidad de tiempo, dado que el proceso vale n en el tiempo t:

$$(\mathcal{L}f)(n) = \lim_{h\to 0} \frac{E[f(N_{t+h}) - f(N_t) \mid N_t = n]}{h} = \lambda[f(n+1) - f(n)]$$

En palabras: $(\mathcal{L}f)(n) = (tasa) \times [valor\ de\ f\ un\ paso\ arriba - valor\ de\ f\ en\ el\ estado\ actual]$

La esperanza condicional tiene sentido porque es función de lo que se condiciona (el valor n). Al tomar $h \to 0$ se van "pescando" los saltos en intervalos muy pequeños. ¿Para qué sirve? Según la clase, para **construir martingalas** y para obtener **semigrupos**, que describen cómo evoluciona el proceso en el tiempo.

3.2 Expansión a corto plazo

La otra lectura del proceso de Poisson es como una **cadena de Markov a tiempo continuo**. Dado que ya llevo n eventos, en un intervalo muy pequeño de longitud h:

$$\mathbb{P}(N_{t+h} - N_t = 1 \mid N_t = n) = \lambda h + o(h)$$
$$\mathbb{P}(N_{t+h} - N_t = 0 \mid N_t = n) = 1 - \lambda h + o(h)$$
$$\mathbb{P}(N_{t+h} - N_t \geq 2 \mid N_t = n) = o(h)$$

Aquí o(h) es la notación "o pequeña": funciones que se hacen despreciables frente a h cuando $h \to 0$. Lo interpreto así: la probabilidad de un evento en un instante muy corto **sólo depende de la tasa y de la longitud h**, no de cuántos eventos llevo; y la probabilidad de dos o más eventos a la vez es tan pequeña que ni siquiera depende de λ, sólo del orden de h.

Ejemplo propio. Con $\lambda = 2$ y $h = 0.01$, la probabilidad exacta de un evento es $\lambda h e^{-\lambda h} \approx 0.01960$, muy cerca de $\lambda h = 0.02$; la de dos o más es ≈ 0.000197, mucho más chica que h.

3.3 Matriz de intensidades y semigrupo

Desde el estado n sólo se puede saltar al estado n + 1, siempre con tasa λ. Es un **proceso de nacimiento puro con nacimientos unitarios**. Su matriz de intensidades (generador) es:

$$q_{n,n+1} = \lambda, \quad q_{n,n} = -\lambda, \quad q_{n,m} = 0\ en\ otro\ caso$$

Esta matriz Q genera un **semigrupo** de matrices de transición $P_t = e^{tQ}$, que cumple la propiedad de semigrupo y se puede derivar:

$$P_{t+s} = P_t P_s, \qquad \frac{d}{dt}P_t = QP_t = P_t Q$$

En la clase se describe al generador como la "huella de primer orden" del semigrupo: mide la **variación media instantánea** de cualquier observable f.

3.4 Ecuaciones de Chapman–Kolmogorov hacia adelante

Para las probabilidades marginales $p_n(t) = \mathbb{P}(N_t = n)$ se obtienen las ecuaciones hacia adelante, que van de forma recursiva:

$$p'_0(t) = -\lambda p_0(t), \qquad p'_n(t) = -\lambda p_n(t) + \lambda p_{n-1}(t),\ n \geq 1$$

con condición inicial $p_0(0) = 1$ y $p_n(0) = 0$ para $n \geq 1$. Resolviéndolas paso a paso:

1. De la primera ecuación: $p_0(t) = e^{\wedge}(-\lambda t)$, así que la probabilidad de que no haya pasado nada decae exponencialmente.
2. Sustituyendo en la de n = 1: $p_1(t) = \lambda t \cdot e^{\wedge}(-\lambda t)$.
3. Repitiendo por inducción: $p_n(t) = e^{\wedge}(-\lambda t)(\lambda t)^n/n!$, que es justamente la ley Poisson(λt).

Así se cierra el círculo: la descripción "local" (lo que pasa en instantes muy pequeños) reproduce la distribución Poisson "global". En palabras de la clase, estas ecuaciones describen el paso **de lo discreto a lo continuo**.

3.5 Fórmula de Dynkin y martingalas

La **fórmula de Dynkin** dice que, para toda función acotada f, el proceso

$$M_t^f = f(N_t) - f(N_0) - \int_0^t (\mathcal{L}f)(N_s)\, ds$$

En palabras: M_t^f = (*valor de f hoy*) − (*valor de f al inicio*) − (*cambio que el generador predice acumulado en el tiempo*)

es una **martingala**. Es decir, el generador "genera" martingalas. El ejemplo de la clase es f(n) = n: entonces $(\mathcal{L}f)(n) = \lambda(n + 1 - n) = \lambda$ y la integral vale λt, así que

$$N_t - \lambda t \ \text{ es una martingala } (\text{proceso de Poisson compensado})$$

Lo interpreto así: si al conteo le quito lo que "espero" que ocurra (λt), lo que queda no tiene tendencia; en promedio no sube ni baja. A λt se le llama el **compensador**.

Ejemplo propio con f(n) = n². Como $(\mathcal{L}f)(n) = \lambda[(n + 1)^2 - n^2] = \lambda(2n + 1)$, el proceso $N_t^2 - \int_0^t \lambda(2N_s + 1)\, ds$ es martingala. Tomando esperanza:

$$E[N_t^2] = \int_0^t \lambda(2\lambda s + 1)\, ds = \lambda^2 t^2 + \lambda t = Var(N_t) + (EN_t)^2$$

4. Caracterización y construcción con exponenciales

La clase resume que el proceso de Poisson queda **caracterizado por cuatro propiedades** equivalentes. Las dos primeras ya las vimos (empieza en cero e incrementos independientes con ley Poisson); las más interesantes son la tercera y la cuarta, porque dan formas de construirlo y simularlo.

Tercera propiedad (construcción). Si $E_1, E_2, \ldots$ son variables aleatorias **independientes e idénticamente distribuidas Exponencial(λ)**, entonces

$$N_t = máx\{n \geq 0 : E_1 + E_2 + \cdots + E_n \leq t\}$$

En palabras: N_t = *el mayor número de esperas exponenciales cuya suma todavía cabe antes del tiempo t*

Es como una "inversa generalizada" de las sumas, que tienen distribución gamma. Esto da un algoritmo de simulación muy simple, porque las exponenciales se obtienen de uniformes:

$$E_i = -\frac{1}{\lambda} ln(U_i), \quad U_i \sim Uniforme(0,1)$$

1. Generar uniformes $U_1, U_2, \ldots$ y convertirlas en exponenciales con $-\ln(U_i)/\lambda$.
2. Ir sumando las esperas: $S_1 = E_1$, $S_2 = E_1 + E_2$, …
3. Contar cuántas sumas quedan por debajo de t: ese número es N_t.

La idea de la prueba, según la clase, usa la **pérdida de memoria** de la exponencial, las propiedades de semigrupo y las ecuaciones de Kolmogorov.

5. Momentos y covarianza

5.1 Funciones generadoras

Los momentos se recuperan con transformadas. La clase muestra dos (y menciona la función característica):

$$Generadora\ de\ probabilidades\colon\ E[z^{N_t}] = exp[\lambda t(z-1)]$$

$$Transformada\ de\ Laplace\colon\ E\left[e^{-\theta N_t}\right] = exp\left[\lambda t(e^{-\theta}-1)\right]$$

$$Función\ característica\colon\ E\left[e^{iuN_t}\right] = exp\left[\lambda t(e^{iu}-1)\right]$$

Derivando y evaluando en θ = 0 se obtienen los momentos. Como N_t es Poisson, la media y la varianza **coinciden**:

$$E[N_t] = \lambda t, \qquad Var(N_t) = \lambda t$$

5.2 Covarianza entre dos tiempos

Para s ≤ t, el truco de la clase es escribir N_t como suma de dos incrementos sobre intervalos ajenos:

$$N_t = (N_s - N_0) + (N_t - N_s)$$

Como los incrementos son independientes, Cov($N_s, N_t - N_s$) = 0 y entonces

$$Cov(N_s, N_t) = Cov(N_s, N_s) + Cov(N_s, N_t - N_s) = Var(N_s) = \lambda s$$

$$Cov(N_s, N_t) = \lambda \cdot mín(s,t)$$

En palabras: $covarianza = (tasa) \times (el\ menor\ de\ los\ dos\ tiempos)$

La clase comenta que la función mín(s, t) es un **kernel** (núcleo de covarianza), igual que en otros procesos que ya se habían visto. **Ejemplo propio:** con λ = 2, Cov(N_2, N_5) = 2 · 2 = 4, y la correlación es 4/√(4·10) = √(2/5) ≈ 0.632.

6. Tiempos de llegada y tiempos entre llegadas

6.1 Definiciones

Para cada n ≥ 1 se define el **tiempo de llegada** del n-ésimo evento como la primera vez que el proceso alcanza el nivel n, y los **tiempos entre llegadas** como las diferencias:

$$T_n = ínf\{t \geq 0 : N_t \geq n\}, \qquad X_n = T_n - T_{n-1}, \quad T_0 = 0$$

Como es una suma telescópica, $T_n = X_1 + \cdots + X_n$. Parece simple, pero la clase insiste en que es una **equivalencia profunda**. Los T_n forman un **proceso de renovación**.

6.2 Distribuciones

La proposición central dice que los tiempos entre llegadas son **independientes e idénticamente distribuidos Exponencial(λ)**, y por lo tanto su suma tiene distribución **gamma**:

$$X_n \sim Exp(\lambda)\ i.i.d., \qquad T_n \sim Gamma(n,\lambda), \quad f_{T_n}(t) = \frac{\lambda e^{-\lambda t}(\lambda t)^{n-1}}{(n-1)!}, \qquad t > 0$$

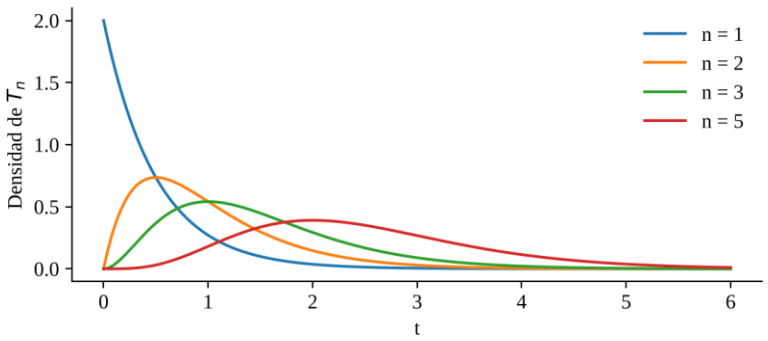


Figura 2. Densidad gamma del n-ésimo tiempo de llegada con λ = 2: mientras más eventos espero, más tarde y más disperso ocurre.

6.3 La dualidad entre tiempos y conteos

El resultado que más se comenta en la clase es la **dualidad** entre eventos:

$$\{T_n \leq t\} = \{N_t \geq n\}$$

En palabras: "el n − ésimo evento ya ocurrió antes de t" es lo mismo que "hasta t hay al menos n eventos"

Lo leo en las dos direcciones: si el n-ésimo evento ocurrió antes de t, necesariamente ya hay al menos n eventos en [0, t]; y si hay al menos n eventos antes de t, el n-ésimo tuvo que ocurrir antes de t. De aquí sale directamente la función de distribución de la gamma usando la Poisson:

$$\mathbb{P}(T_n \leq t) = \mathbb{P}(N_t \geq n) = 1 - \sum_{k=0}^{n-1} e^{-\lambda t} \frac{(\lambda t)^k}{k!}$$

Ejemplo propio. Con λ = 2, la probabilidad de que el tercer cliente llegue antes de t = 1 es $\mathbb{P}(N_1 \geq 3) = 1 - e^{-2}(1 + 2 + 2) = 1 - 5e^{-2} \approx 0.3233$.

La clase explica que esto es un caso especial de una dualidad más general entre **subordinadores** y **tiempos de paro (de llegada)**: en un proceso creciente càdlàg siempre se puede definir su inversa generalizada, y uno se reconstruye a partir del otro. Del tiempo t paso a un conteo N_t, y del conteo n paso a un tiempo T_n; son transformaciones duales. Visto así, el proceso de Poisson es un **subordinador de Lévy de puro salto**: creciente, con incrementos independientes y estacionarios, y que sólo se mueve con saltos. Esto es clave para estudiar otras estructuras con saltos.

6.4 Conteo y renovación a la vez

Como consecuencia, el proceso de Poisson es **al mismo tiempo un proceso de conteo y un proceso de renovación**. Se puede estudiar con la teoría de procesos puntuales o con la teoría de renovación. La idea que lo sostiene todo es la **pérdida de memoria**:

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$$

La clase recuerda que entre todas las variables absolutamente continuas, **la exponencial es la única** con esta propiedad; en el caso discreto, la única es la **geométrica**. En mis palabras: no importa cuánto lleve esperando, lo que falta para el siguiente evento tiene la misma distribución que al principio.

7. Tiempos de llegada condicionados: estadísticos de orden uniformes

Si se toman los tiempos de llegada por separado ya no son independientes ni tienen la misma ley. Pero hay un resultado muy importante cuando **condiciono a cuántos eventos hubo**. Para t > 0 fijo:

$$(T_1, \dots, T_n) \mid (N_t = n) \sim (U_{(1)}, \dots, U_{(n)})$$

En palabras: dado que hubo n eventos hasta t, sus tiempos son como n uniformes en $[0, t]$ *ya ordenadas*

donde $U_{(1)} \leq \cdots \leq U_{(n)}$ son los **estadísticos de orden** de n variables uniformes independientes en [0, t]. Su densidad conjunta es constante sobre la región ordenada:

$$f_{T_1,\dots,T_n \mid N_t=n}(s_1, \dots, s_n) = \frac{n!}{t^n}, \quad 0 < s_1 < \cdots < s_n < t$$

Si divido cada tiempo entre t (la longitud del intervalo), los cocientes T_i/t son estadísticos de orden de uniformes en [0, 1], con soporte en un **simplejo**. Además, los **incrementos normalizados** $(T_1, T_2 - T_1, \dots, t - T_n)/t$ siguen una ley **Dirichlet(1, …, 1)**.

Lo interpreto así: la información condicional **sólo fija cuántos saltos hubo** en el horizonte, pero **no altera cómo se reparten** dentro del intervalo; la geometría interna sigue siendo uniforme. Esto separa la simulación en dos piezas:

1. Simular el **número de saltos**: $N_t \sim$ Poisson(λt).
2. Simular **dónde caen**: generar N_t uniformes en [0, t] y ordenarlas.

La clase comenta que generar el proceso así suele ser **más rápido** que otros métodos, y que más adelante se compararán algoritmos (Monte Carlo y otros) para ver cuál conviene. El ejemplo del video toma t = 4 y $N_4 = 6$: los seis tiempos ordenados se comportan como estadísticos de orden de uniformes. La verificación empírica compara el histograma de Monte Carlo con la densidad teórica, que es una **línea horizontal** (uniformidad). Yo repetí ese experimento simulando el proceso con exponenciales y quedándome sólo con las trayectorias que tuvieron exactamente 6 eventos:

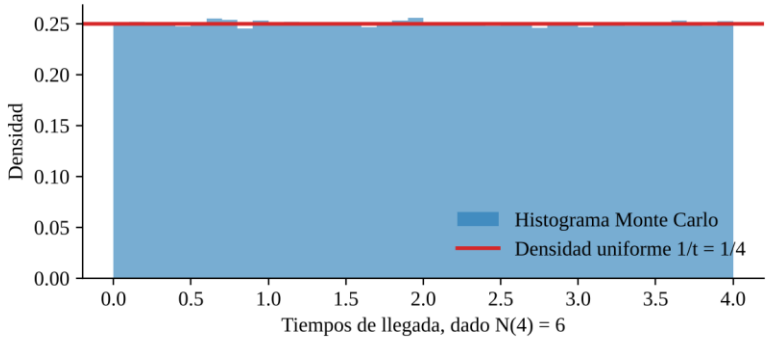


Figura 3. Tiempos de llegada simulados con exponenciales, condicionados a N(4) = 6. El histograma queda pegado a la densidad uniforme 1/4.

8. Hacia dónde sigue el tema

Al final, la clase adelanta los siguientes temas:

- **Martingalas y compensadores.** El proceso compensado $M_t = N_t - \lambda t$ es una martingala cuadrado integrable, y su variación cuadrática predecible es $\langle M \rangle_t = \lambda t$, que coincide con $\mathrm{Var}(M_t)$.
- **Cambio de medida (Radon–Nikodym).** Igual que en las caminatas aleatorias, centrar el proceso no basta: se quiere **quitar la tendencia (drift) trabajando con el mismo proceso**. Para eso se cambia la

medida de probabilidad con una densidad de Radon–Nikodym construida de forma precisa, y los compensadores son justamente lo que hay que ajustar al cambiar de medida.

9. Resumen de resultados

Concepto	Resultado
Ley de los incrementos	$N_t - N_s \sim \text{Poisson}(\lambda(t-s))$, independiente del pasado
Ley marginal	$N_t \sim \text{Poisson}(\lambda t)$
Generador	$(\mathscr{A}f)(n) = \lambda[f(n+1) - f(n)]$
Corto plazo	$P(1 \text{ salto}) = \lambda h + o(h)$; $P(\geq 2 \text{ saltos}) = o(h)$
Martingala compensada	$N_t - \lambda t$
Media y varianza	$E[N_t] = \text{Var}(N_t) = \lambda t$
Covarianza	$\text{Cov}(N_s, N_t) = \lambda \cdot \text{mín}(s, t)$
Tiempos entre llegadas	$X_n \sim \text{Exp}(\lambda)$, i.i.d.
Tiempo de la n-ésima llegada	$T_n \sim \text{Gamma}(n, \lambda)$
Dualidad	$\{T_n \leq t\} = \{N_t \geq n\}$
Condicionado a $N_t = n$	Tiempos = estadísticos de orden de n uniformes en [0, t]

Antes de usar el modelo en un problema real, yo revisaría:

1. Que los eventos lleguen **de uno en uno** (no hay llegadas simultáneas).
2. Que lo que pasa en intervalos ajenos sea **independiente**.
3. Que la tasa sea **constante** en el tiempo; si no, se necesita un proceso no homogéneo.
4. Que la media y la varianza observadas del conteo sean **parecidas**, como exige la Poisson.

Conclusión

Después de ver la clase, me queda claro que el proceso de Poisson es mucho más que una distribución: es un objeto que se puede mirar desde varios ángulos y en todos dice lo mismo. Como proceso de conteo, sus incrementos son independientes y Poisson con parámetro proporcional a la longitud del intervalo. Como cadena de Markov, es un proceso de nacimiento puro con tasa λ, cuyo generador produce las ecuaciones de Kolmogorov y, con la fórmula de Dynkin, martingalas como $N_t - \lambda t$.

Como proceso de renovación, se construye sumando esperas exponenciales independientes, y la dualidad $\{T_n \leq t\} = \{N_t \geq n\}$ conecta los tiempos con los conteos. Y si condiciono al número de eventos, los tiempos se reparten de forma uniforme, lo que da un método rápido para simular.

Lo más valioso para mí es que todo descansa en una sola idea: la **pérdida de memoria** de la exponencial. Gracias a ella el proceso "olvida" su pasado en cada instante, y eso es lo que hace que sea tan útil para modelar llegadas de clientes, llamadas o siniestros en actuaría.