Teoría de inventarios

Nayeli Cruz Fonseca · Licenciatura en Actuaría · Octubre de 2026

Introducción

La teoría de inventarios es, para mí, la forma ordenada de responder una pregunta que tiene cualquier negocio que guarda mercancía: **cuánto pedir** y **cuándo pedirlo**. Un inventario sirve para separar el momento en que se compra o se produce del momento en que se consume, pero guardarlo cuesta. Por eso toda decisión de inventario equilibra dos fuerzas: pedir mucho de una vez ahorra en costos fijos de pedido, y guardar mucho cuesta en capital, almacén y, si me quedo corto, en faltantes y clientes molestos.

Los apuntes recorren primero modelos donde la demanda se conoce con certeza (deterministas), después modelos donde la demanda es aleatoria (estocásticos) y terminan con problemas de varios productos que comparten un presupuesto o un espacio limitado. Cada modelo se deriva, se calcula con un ejemplo numérico y se interpreta como una decisión real.

La idea central que yo rescato es que **una fórmula óptima sólo es óptima dentro de sus supuestos**. Dos fórmulas que se ven parecidas pueden describir problemas económicos muy distintos, así que antes de calcular siempre tengo que preguntarme qué estoy decidiendo, qué costo estoy minimizando, qué servicio le prometo al cliente y bajo qué condiciones vale la cuenta.

1. Conceptos básicos y marco matemático

1.1 Variables del sistema

Para describir un inventario en el tiempo, los apuntes usan cinco cantidades:

Símbolo	Qué representa
I(t)	Inventario disponible en el almacén en el momento t
B(t)	Demanda que todavía no se surte (pedidos pendientes o *backlog*)
O(t)	Pedidos ya hechos que todavía no llegan
X(t) = I(t) − B(t)	Inventario neto: lo que tengo menos lo que debo
Y(t) = X(t) + O(t)	Posición de inventario, la que se usa para decidir cuándo reordenar

Cuando las ventas se pierden (el cliente se va), B(t) = 0. Una advertencia del texto que me parece clave: en ese caso **no se debe representar con inventario negativo** una venta que nunca ocurrió.

1.2 Política y objetivo

Una política π asigna momentos y cantidades de pedido con la información disponible en cada momento. Su costo promedio esperado de largo plazo es

$$J(\pi) \;=\; \lim_{T\to\infty} \sup \frac{1}{T}\, E_\pi\big[\text{costo relevante total en } [0,T]\big]$$

$$\textit{En palabras: } J(\pi) \;=\; \frac{\text{costo esperado acumulado hasta el tiempo } T}{\text{duración del horizonte } T} \;\text{cuando } T \text{ se hace muy grande}$$

Si el horizonte es finito, en lugar de un promedio se minimiza el costo esperado acumulado, a veces con un valor de rescate al final.

1.3 Notación

Símbolo	Significado	Unidades
D	Demanda anual	unidades/año
K	Costo fijo por pedido	pesos/pedido
c	Costo de compra unitario	pesos/unidad
h	Costo de mantener una unidad	pesos/(unidad·año)
p	Costo de una unidad pendiente	pesos/(unidad·año)
Q	Tamaño del lote	unidades
T	Duración del ciclo	años
L	Tiempo de entrega	años o días
P	Tasa de producción (P > D)	unidades/año

Todas las comparaciones de costos tienen que usar unidades de tiempo compatibles.

1.4 Cuatro clasificaciones

Un modelo de inventarios se clasifica según cuatro preguntas independientes: si la demanda es determinista o aleatoria; si el tiempo es continuo o discreto; si la demanda no surtida queda pendiente o se pierde; y si la reposición llega de golpe o se reparte durante un periodo de producción. Además hay que aclarar si los pedidos son continuos o enteros, si el tiempo de entrega es cero o positivo y qué restricciones están activas. El costo de compra cD se puede quitar del EOQ clásico porque no depende de Q, pero **no** cuando hay ventas perdidas, descuentos por volumen o cuando lo que se vende depende de la decisión.

1.5 Cómo leer un modelo

Los apuntes insisten en que la respuesta matemática no es todavía la respuesta gerencial. Antes de dar un resultado, yo separo cuatro cosas:

1. La **variable de control** (por ejemplo, el tamaño del lote o el punto de reorden).
2. La **cantidad que se minimiza** (normalmente un costo anual).
3. El **compromiso de servicio** con el cliente.
4. Los **supuestos** bajo los que el cálculo es válido.

Decir que un lote es "óptimo" significa óptimo dentro del modelo; no garantiza que el almacén, los clientes o los proveedores se comporten como suponen las fórmulas.

2. Cantidad económica de pedido (EOQ clásico)

2.1 Supuestos y función de costo

La demanda llega a tasa constante D, el tiempo de entrega es cero (o conocido), el pedido llega completo de golpe, no se permiten faltantes y cada pedido cuesta K. Con un lote fijo Q, cada ciclo dura T = Q/D y el inventario baja en línea recta de Q a cero, así que su promedio es Q/2. El costo anual relevante es

$$C(Q) = \frac{KD}{Q} + \frac{hQ}{2}, \quad Q > 0$$

En palabras: $C(Q) = \frac{(costo\ por\ pedido)(demanda\ anual)}{tamaño\ del\ lote} + \frac{(costo\ de\ guardar\ una\ unidad\ un\ año)(tamaño\ del\ lote)}{2}$

El primer término es el costo de hacer pedidos y baja cuando Q crece; el segundo es el costo de guardar y sube con Q.

2.2 Derivación

Si el ciclo empieza con I(0) = Q, entonces I(t) = Q − Dt para 0 ≤ t ≤ T. El área bajo el inventario en un ciclo es

$$\int_0^{Q/D} (Q - Dt)\, dt = QT - \frac{DT^2}{2} = \frac{Q^2}{2D}$$

Dividiendo entre T sale el promedio Q/2. En un año hay D/Q pedidos, así que el costo fijo anual es KD/Q, y el de guardar es hQ/2. Derivo:

$$C'(Q) = -\frac{KD}{Q^2} + \frac{h}{2}, \quad C''(Q) = \frac{2KD}{Q^3} > 0$$

Como la segunda derivada es positiva, la función es convexa y el punto crítico es un mínimo global; además C(Q) → ∞ cuando Q → 0 o Q → ∞, lo que asegura que el mínimo existe y es único. Igualando a cero:

$$Q^* = \sqrt{\frac{2KD}{h}}, \quad C(Q^*) = \sqrt{2KDh}$$

En palabras: $Q^* = \sqrt{\frac{2\,(costo\ por\ pedido)(demanda\ anual)}{costo\ de\ guardar\ una\ unidad\ un\ año}}$

En el óptimo el costo de pedir es igual al costo de guardar, KD/Q* = hQ*/2. Esto sale de la condición de primer orden, pero el texto aclara que no es una propiedad de todas las políticas de inventario.

2.3 Ejemplo: un distribuidor

Con D = 12,000 unidades/año, K = 180 y h = 6 (300 días hábiles al año):

$$2KD = 4{,}320{,}000, \quad \frac{2KD}{h} = 720{,}000, \quad Q^* = \sqrt{720{,}000} = 600\sqrt{2} \approx 848.53\ unidades$$

$$\frac{D}{Q^*} = 10\sqrt{2} \approx 14.14\ pedidos/año, \quad T^* = \frac{\sqrt{2}}{20} \approx 0.0707\ años \approx 21.21\ días\ hábiles$$

$$C(Q^*) = \frac{180(12{,}000)}{848.53} + \frac{6(848.53)}{2} = 2{,}545.58 + 2{,}545.58 = 3600\sqrt{2} \approx 5{,}091.17$$

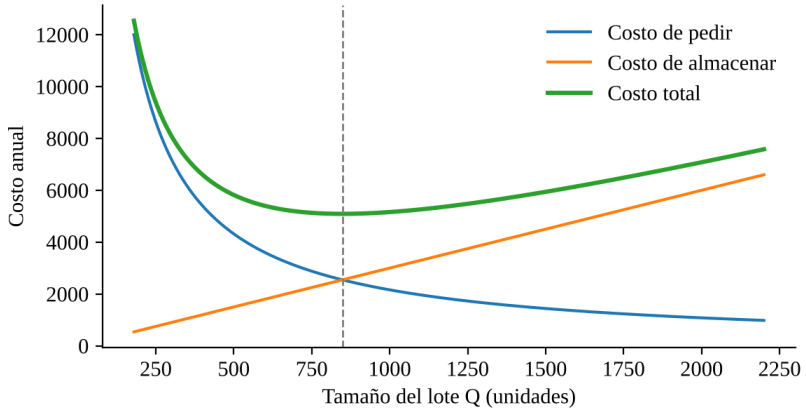


Figura 1. Costo de pedir, de almacenar y total. El mínimo está donde se cruzan las dos primeras curvas.

Yo lo interpreto así: al distribuidor le conviene pedir unas 849 unidades cada vez, unas 14 veces al año. Pedir las 12,000 de golpe ahorraría pedidos pero llenaría el almacén; pedir poquito ahorraría almacén pero obligaría a hacer muchísimos pedidos. Los 5,091.17 **sólo** son costos de pedir y guardar; no son el presupuesto de compras ni la utilidad. Si se pide el gasto total, hay que sumar cD.

Como la curva total es plana cerca del óptimo, un lote cercano (por ejemplo, una tarima completa) puede ser aceptable; lo correcto es comparar la **diferencia en costo**, no sólo en unidades.

2.4 Sensibilidad y tiempo de entrega

Tomando logaritmos en la fórmula se ve que Q* es proporcional a $\sqrt{D}$ y a $\sqrt{K}$, e inversamente proporcional a $\sqrt{h}$ (Proposición 2.1). Si la demanda se duplica, el lote crece sólo por un factor $\sqrt{2}$, alrededor de 41 %, y el número de pedidos también sube 41 %. En mis palabras: vender más no justifica un aumento proporcional de cada embarque.

Si el proveedor tarda L años y la demanda es segura, se reordena cuando la posición de inventario llega a R = DL y el lote óptimo no cambia. Ojo: reordenar mirando sólo el inventario físico engaña cuando hay varios pedidos en camino.

3. Faltantes con pedidos pendientes

3.1 Modelo

Ahora toda la demanda no surtida se entrega después, porque el cliente espera. Sea S el inventario máximo y B el máximo de pedidos pendientes; en cada ciclo se piden Q = S + B unidades. El inventario positivo dura S/D y el faltante dura B/D. Como ambas partes tienen forma de triángulo, el inventario promedio es $S^2/(2Q)$ y el faltante promedio es $B^2/(2Q)$. El costo anual es

$$C(Q,S) = \frac{KD}{Q} + \frac{hS^2}{2Q} + \frac{p(Q-S)^2}{2Q}, \quad 0 \le S \le Q$$

En palabras: $C = \frac{(\text{costo por pedido})(\text{demanda})}{\text{lote}} + \frac{(\text{costo de guardar})(\text{inv.máximo})^2}{2\,(\text{lote})} + \frac{(\text{costo de faltante})(\text{faltante máx.})^2}{2\,(\text{lote})}$

3.2 Derivación

Para Q fijo derivo respecto a S:

$$\frac{\partial C}{\partial S} = \frac{hS - p(Q-S)}{Q} = 0 \iff (h+p)S = pQ$$

La segunda derivada $(h + p)/Q > 0$ confirma el mínimo. Sustituyendo $S = pQ/(h + p)$ se obtiene $hS^2 + pB^2 = Q^2 \cdot hp/(h + p)$, y el costo queda en una sola variable:

$$C(Q) = \frac{KD}{Q} + \frac{hp}{2(h+p)}\,Q$$

$$\boxed{Q^*_{BO} = \sqrt{\frac{2KD(h+p)}{hp}}, \quad S^* = \frac{p}{h+p}\,Q^*_{BO}, \quad B^* = \frac{h}{h+p}\,Q^*_{BO}}$$

En palabras: $Q^*_{BO} = \sqrt{\frac{2\,(\text{costo por pedido})(\text{demanda})(\text{costo de guardar} + \text{costo de faltante})}{(\text{costo de guardar})(\text{costo de faltante})}}$

Cuando $p \to \infty$ (faltar sale carísimo) la fórmula regresa al EOQ clásico. Es importante que aquí p se cobra **por unidad pendiente por año**; una cuota fija por faltante o por unidad no surtida sería otro modelo.

3.3 Ejemplo

Con los mismos datos y p = 24 tengo h + p = 30, así que S* = 4/5 Q* y B* = 1/5 Q*:

$$Q_{BO}^{*} = \sqrt{\frac{2(180)(12{,}000)(30)}{6(24)}} = \sqrt{900{,}000} = 300\sqrt{10} \approx 948.68, \quad S^{*} = 240\sqrt{10} \approx 758.95, \quad B^{*} = 60\sqrt{10} \approx 189.74$$

Concepto	Valor
Costo de pedir KD/Q*	2,276.84
Costo de guardar hS*²/(2Q*)	1,821.47
Costo de faltante pB*²/(2Q*)	455.37
Costo anual total	**4,553.68**
Días con inventario / días con faltante	18.97 / 4.74 días hábiles

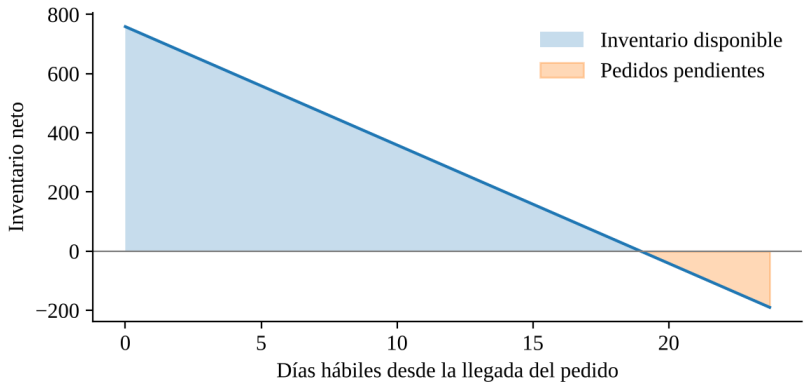


Figura 2. Inventario neto en un ciclo con pedidos pendientes.

Yo lo interpreto así: esta política acepta a propósito quedarse sin mercancía, y en el peor momento se le deben unos 190 artículos a los clientes. Durante 4/5 del ciclo hay inventario y durante 1/5 hay faltante; son **fracciones de tiempo**, no probabilidades de atender a un cliente. El ahorro de unos 537.49 al año frente al EOQ clásico sólo es real si los clientes de verdad esperan y si su espera vale p = 24 por unidad-año. Si los clientes se van, el ahorro es ficticio y el modelo correcto es el de ventas perdidas.

4. Ventas perdidas

Una venta perdida es demanda que **desaparece** cuando no hay mercancía; no es una deuda con el cliente. Por eso su costo no se puede confundir con el costo de espera p. En lugar de forzar las fórmulas anteriores, los apuntes plantean un modelo por periodos: la demanda N de cada periodo es aleatoria e independiente, y antes de cada periodo se repone hasta un nivel entero S. Cada unidad sobrante cuesta h_o y cada venta perdida cuesta c_u. El costo esperado por periodo es

$$g(S) = h_o\, E(S - N)^{+} + c_u\, E(N - S)^{+}, \quad x^{+} = \max(x, 0)$$

$$\textit{En palabras: } g(S) = (\textit{costo por sobrante})(\textit{sobrante esperado}) + (\textit{costo por venta perdida})(\textit{ventas perdidas esperadas})$$

Se supone que reponer cada periodo es posible y que no hay costo fijo de pedido; si lo hubiera, los periodos quedarían conectados y el problema cambiaría. Para encontrar el óptimo comparo el costo de subir una unidad:

si la demanda no llega a S, esa unidad sobra y cuesta h_o; si la demanda supera S, evita una venta perdida y ahorra c_u. Promediando:

$$g(S+1) - g(S) = h_o\,Pr(N \le S) - c_u\,Pr(N \ge S+1) = (h_o + c_u)F_N(S) - c_u$$

Esta diferencia cambia de signo en el **fractil crítico**: el S óptimo es el menor entero que cumple

$$F_N(S^*) \ge \frac{c_u}{c_u + h_o}$$

En palabras: $probabilidad\ de\ que\ la\ demanda\ no\ pase\ de\ S^* \ge \frac{costo\ de\ faltar}{costo\ de\ faltar + costo\ de\ sobrar}$

Este resultado no necesita aproximación normal.

4.1 Ejemplo con Poisson(22)

Con N ~ Poisson(22), $h_o = 2$ y $c_u = 17$, la fracción crítica es 17/19 ≈ 0.8947.

S	F(S)	g(S)
26	0.8324	18.39
27	0.8775	17.20
28	**0.9129** (primero ≥ 17/19)	**16.88** (mínimo)
29	0.9398	17.22

En mis palabras: elijo 28 unidades antes de ver la demanda y, como quedarme corto (17) me cuesta mucho más que sobrar (2), conviene tener más que el promedio de 22. La fracción 17/19 **no** significa que se venda 89.47 % de las unidades ni que se pierda 10.53 % de la demanda; es sólo un umbral de probabilidad acumulada. La probabilidad de agotarse, Pr(N > 28) ≈ 0.087, y las ventas perdidas esperadas, $E(N-28)^+ \approx 0.26$ unidades, son dos medidas de riesgo distintas.

4.2 Ejemplo con Poisson(35)

Con media 35, costo de sobrante 5 y de faltante 18, la fracción crítica es 18/23 ≈ 0.7826. Como F(39) = 0.7802 < 0.7826 ≤ F(40) = 0.8249, el óptimo es **S = 40**, con pérdida esperada de 40.89. La suma infinita se calcula cortando la cola de probabilidad despreciable:

$$g(40) = 5\sum_{n=0}^{40}(40-n)\,Pr(N=n) + 18\sum_{n=41}^{\infty}(n-40)\,Pr(N=n)$$

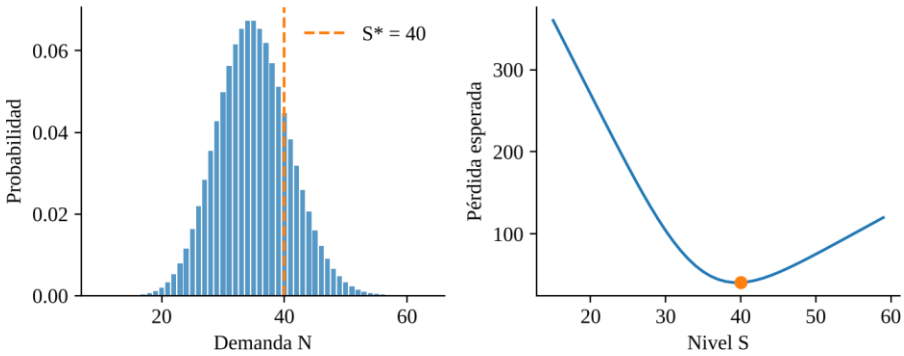


Figura 3. Demanda Poisson(35) con S* = 40 (izquierda) y pérdida esperada según S (derecha).

Con ventas perdidas no hay inventario negativo que pase al siguiente periodo.

5. Demanda entera y lotes enteros

Los apuntes distinguen dos ideas: una demanda determinista contada en piezas que se aproxima de forma continua en el tiempo, y una demanda aleatoria entera que necesita una distribución discreta. En el primer caso el EOQ se resuelve sobre números enteros.

Proposición 2.5. Si $q_0 = \sqrt{(2KD/h)}$, el lote entero óptimo está entre $\lfloor q_0 \rfloor$ y $\lceil q_0 \rceil$. La razón es que C(Q) baja antes de q_0 y sube después, así que cualquier entero más lejano cuesta más que el vecino de su lado. Hay que **comparar los costos exactos**, porque la curva no es simétrica:

$$C(848) = \frac{2{,}160{,}000}{848} + 3(848) = 5{,}091.1698, \quad C(849) = \frac{2{,}160{,}000}{849} + 3(849) = 5{,}091.1696$$

Gana 849. Yo lo interpreto así: el ajuste es pequeño y lo que importa es la factibilidad. Si el proveedor sólo vende cajas de 24, los candidatos son múltiplos como 840 (5,091.43) y 864 (5,092.00). Y si además hay límites de espacio o presupuesto, redondear cada cantidad por separado puede violar la restricción, así que primero defino el conjunto factible y luego aplico la regla. Si la demanda llega en lotes, el promedio Q/2 puede dejar de ser exacto, y con demanda aleatoria discreta, sustituirla por su media en general cambia la decisión óptima.

6. Reposición gradual: cantidad económica de producción

Ahora la empresa produce a tasa P > D. Mientras produce, el inventario sube a la tasa neta P − D; cuando para, baja a la tasa D. Una corrida de Q unidades dura Q/P y el ciclo dura Q/D, así que el inventario máximo y el costo son

$$I_{máx} = \frac{Q}{P}(P - D) = Q\left(1 - \frac{D}{P}\right), \quad C_{EPQ}(Q) = \frac{KD}{Q} + \frac{hQ}{2}\left(1 - \frac{D}{P}\right)$$

$$Q^*_{EPQ} = \sqrt{\frac{2KD}{h(1 - D/P)}}$$

En palabras: $Q^*_{EPQ} = \sqrt{\dfrac{2\,(costo\ de\ preparación)(demanda)}{(costo\ de\ guardar)(1 - demanda/tasa\ de\ producción)}}$

Como se va vendiendo mientras se produce, el inventario nunca llega a Q y el lote óptimo es **mayor** que el EOQ. Si $P \to \infty$ se recupera el EOQ, y si $P \le D$ la fórmula no sirve, porque no se puede reponer más rápido de lo que se consume.

Ejemplo. Con P = 48,000, D = 12,000, K = 180 y h = 6, el factor es 1 − D/P = 3/4:

$$Q^*_{EPQ} = \sqrt{960{,}000} = 400\sqrt{6} \approx 979.80, \quad I_{máx} = 300\sqrt{6} \approx 734.85, \quad C = 1800\sqrt{6} \approx 4{,}409.08$$

La producción dura 0.0204 años (6.12 días hábiles) y el ciclo 0.0816 años (24.49 días hábiles).

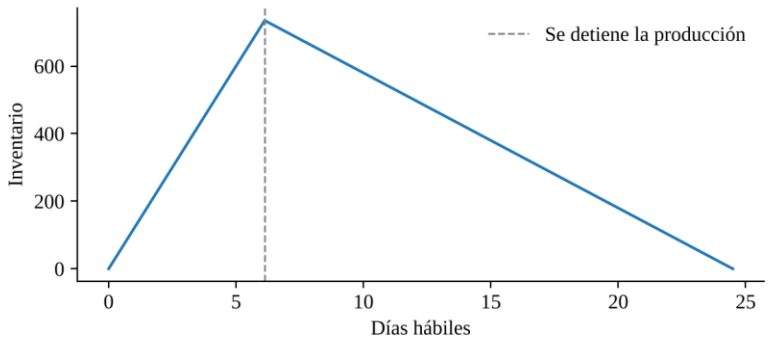


Figura 4. Ciclo EPQ: el inventario sube mientras se produce y baja después.

En mis palabras: se producen unas 980 unidades por corrida, pero el inventario máximo es de 735 porque unas 245 salen mientras la máquina trabaja, y eso no es desperdicio. La producción ocupa D/P = 1/4 del ciclo, así que la máquina queda libre el resto. Si se comparte con otros productos, entran la programación y los cambios de producto, que el EPQ por sí solo no resuelve.

7. Modelos estocásticos

Cuando la demanda es aleatoria, reponer se vuelve una decisión bajo incertidumbre. Los apuntes resuelven primero un problema de un solo periodo y luego una política continua; son dos problemas matemáticamente distintos.

7.1 El problema del vendedor de periódicos (newsvendor)

Se hace **un solo pedido** de q unidades antes de conocer la demanda N. Sea c_o el costo neto de una unidad sobrante (precio menos rescate) y c_u el de una faltante (ganancia perdida más penalización). La pérdida esperada y su derivada son

$$G(q) = c_o\,E(q - N)^+ + c_u\,E(N - q)^+, \quad G'(q) = c_o F(q) - c_u[1 - F(q)]$$

$$F(q^*) = \frac{c_u}{c_o + c_u}$$

En palabras: $probabilidad\ de\ que\ la\ demanda\ no\ rebase\ q^* = \frac{costo\ de\ quedarse\ corto}{costo\ de\ sobrar + costo\ de\ quedarse\ corto}$

Con demanda entera se toma el menor entero cuya acumulada alcance el umbral. La derivación muestra por qué **pedir la media no es, en general, lo óptimo**. Con N ~ Poisson(35), $c_u = 18$ y $c_o = 5$, la fracción es 18/23, el pedido óptimo es **40 unidades** y la pérdida esperada es 40.89.

Yo lo interpreto así: las cinco unidades arriba de la media son una cobertura porque faltar cuesta más que sobrar, no una señal de que el pronóstico estuviera mal. Hay que distinguir cuatro cantidades: la decisión q = 40, las ventas reales mín(q, N), los sobrantes $(q - N)^+$ y las ventas perdidas $(N - q)^+$. Si se pudiera volver a pedir después de ver la demanda, esta política ya no aplicaría.

7.2 Revisión continua y política (Q, R)

Se pide Q cada vez que la posición de inventario baja al **punto de reorden** R. Con tiempo de entrega L, lo que importa es la demanda durante la entrega, N_L. Un nivel de servicio por ciclo α se impone con

$$Pr(N_L \le R) \ge \alpha, \quad R = F_{N_L}^{-1}(\alpha)$$

Este nivel **no es** la tasa de surtido (fracción de unidades entregadas de inmediato), y fijarlo no garantiza que (Q, R) minimice costos. Si las demandas diarias son independientes con media μ_d y varianza σ_d^2:

$$EN_L = L\mu_d, \quad Var(N_L) = L\sigma_d^2, \quad R \approx L\mu_d + z_\alpha \sigma_d \sqrt{L}$$

En palabras: $R \approx$ *(días de entrega)(demanda diaria promedio) +*
(valor z del servicio)(desviación diaria)$\sqrt{\text{días de entrega}}$

El segundo término es el **inventario de seguridad**. Con tiempo de entrega aleatorio e independiente la varianza cambia a $Var(N_L) = E[L]\sigma_d^2 + Var(L)\mu_d^2$.

Ejemplo con 95 % de servicio. Demanda anual de 12,000 en 300 días ($\mu_d = 40$), $\sigma_d = 16$ y L = 5 días:

$$\mu_L = 200, \quad \sigma_L = 16\sqrt{5} \approx 35.78, \quad R = 200 + 1.6449(35.78) \approx 258.85 \rightarrow 259\ unidades$$

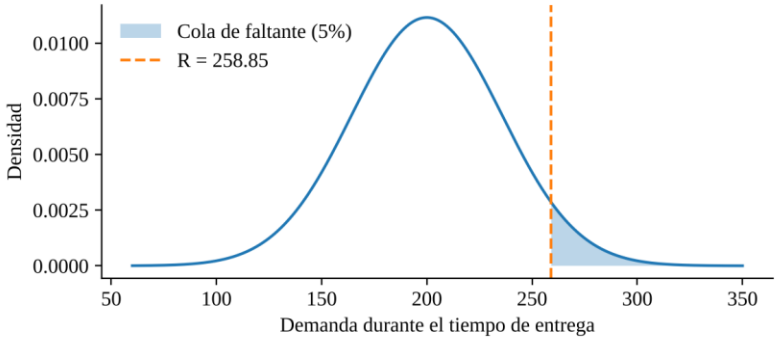


Figura 5. Demanda normal en el tiempo de entrega y punto de reorden al 95 %.

El lote puede tomarse del EOQ (848.53), pero el servicio, los faltantes y el costo del inventario de seguridad se tienen que evaluar juntos. Para un modelo con costo de faltante importa el faltante esperado:

$$E(N_L - R)^+ = \int_R^\infty (x - R) f_{N_L}(x)\, dx = \sigma_L[\varphi(a) - a(1 - \Phi(a))], \quad a = \frac{R - \mu_L}{\sigma_L}$$

La última igualdad usa el cambio $x = \mu_L + \sigma_L z$ y que $\int_a^\infty z\varphi(z)\, dz = \varphi(a)$, porque $\varphi'(z) = -z\varphi(z)$. En el ejemplo da unas 0.75 unidades faltantes por ciclo. Como la normal permite valores negativos, con conteos pequeños o sesgados conviene una Poisson, una binomial negativa o una distribución empírica.

En mis palabras: Q decide **qué tan seguido** pido y R decide **cuándo** disparo el pedido. Subir R me protege más durante la espera pero no cambia cuántas veces pido. La zona sombreada de la figura es una probabilidad de faltante, no el número esperado de unidades perdidas.

8. Restricciones de presupuesto y capacidad

Con varios productos, los lotes óptimos calculados por separado pueden necesitar demasiado espacio o dinero. Para cada artículo i se minimiza

$$mín_{Q_i > 0} \sum_{i=1}^{n} \left(\frac{K_i D_i}{Q_i} + \frac{h_i Q_i}{2} \right)$$

Si a_i es el espacio por unidad, el límite de almacén es $\Sigma\, a_i Q_i \le A$; si c_i es el precio, el límite de capital para un pedido simultáneo es $\Sigma\, c_i Q_i \le M$. Estas restricciones son distintas a limitar el inventario promedio, el gasto anual de compras o el tiempo de una máquina compartida; la que se use tiene que reflejar la situación real.

8.1 Solución con multiplicadores de Lagrange

$$\mathcal{L}(Q,\lambda) \;=\; \sum_{i=1}^{n}\left(\frac{K_i D_i}{Q_i} + \frac{h_i Q_i}{2}\right) + \lambda\left(\sum_{i=1}^{n} c_i Q_i \;-\; M\right), \quad \lambda \;\ge\; 0$$

Derivando cada coordenada por separado:

$$-\frac{K_i D_i}{Q_i^2} + \frac{h_i}{2} + \lambda c_i \;=\; 0 \;\;\Longrightarrow\;\; Q_i(\lambda) \;=\; \sqrt{\frac{2K_i D_i}{h_i \;+\; 2\lambda c_i}}$$

$$\textit{En palabras: } Q_i \;=\; \sqrt{\frac{2\,(\textit{costo por pedido})(\textit{demanda})}{(\textit{costo de guardar}) + 2\,(\textit{multiplicador})(\textit{precio unitario})}}$$

Por holgura complementaria, $\lambda(\Sigma c_i Q_i - M) = 0$. Primero pruebo $\lambda = 0$; si el presupuesto no alcanza, resuelvo $\Sigma c_i Q_i(\lambda) \;=\; M$. Como cada $Q_i(\lambda)$ baja cuando λ sube, la bisección o el método de Brent funcionan bien. Éstas son las condiciones de **Karush–Kuhn–Tucker**, y como el objetivo es estrictamente convexo y el conjunto factible es convexo, dan el único óptimo global. Con una segunda restricción de espacio:

$$Q_i(\lambda,\eta) \;=\; \sqrt{\frac{2K_i D_i}{h_i \;+\; 2\lambda c_i \;+\; 2\eta a_i}}, \quad \lambda,\eta \;\ge\; 0$$

Los multiplicadores dicen cuánto bajaría el costo mínimo al relajar un poco el presupuesto o el espacio. Siempre hay que **verificar** qué restricción está activa, no suponerlo.

8.2 Ejemplo: tres productos

D = (12,000; 8,000; 5,000), K = (180; 120; 90), h = (6; 4; 3), c = (20; 35; 25) y M = 13,000.

	Artículo 1	Artículo 2	Artículo 3	Dinero por pedido	Costo anual
Sin restricción	848.53	692.82	547.72	54,912.34	9,505.62
Con presupuesto	266.79	138.76	112.30	13,000.00	20,268.00

El multiplicador resultante es $\lambda \approx 1.367$, y el costo de 20,268 no incluye las compras $\Sigma c_i D_i$.

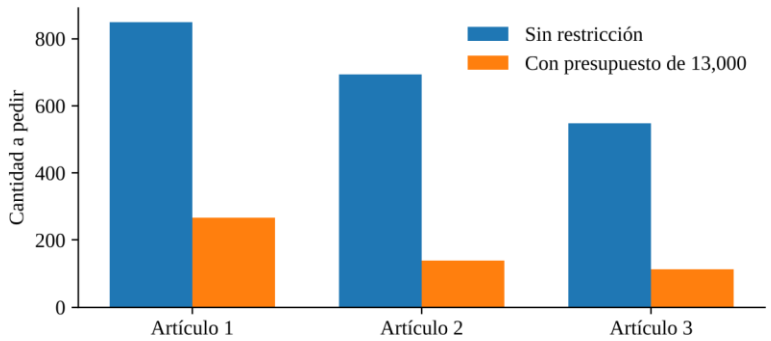


Figura 6. Lotes EOQ sin restricción comparados con los lotes bajo presupuesto.

Yo lo interpreto así: con sólo 13,000 por pedido no alcanza para los lotes EOQ, así que la solución pide lotes más chicos y más seguido. Los 20,268 se comparan con el costo sin restricción (9,505.62), **no** con los 13,000, porque miden cosas distintas en escalas de tiempo distintas. λ es el valor marginal de un peso más de presupuesto por pedido; no es una tasa de interés ni un precio. Y si la empresa quisiera más almacén, tendría que re-optimizar con los a_i, porque un límite de dinero y uno de espacio no dan la misma asignación.

Indivisibilidad. Redondear cada lote por separado puede violar el presupuesto; el problema entero es no lineal y separable, y para casos chicos conviene enumerar o usar un *solver*. Además, pedir todo junto puede tener costos o beneficios de coordinación que el modelo no incluye.

9. Unidades, cómputo y validación

Los apuntes incluyen un archivo de Python (*inventory_examples.py*) que recalcula todos los ejemplos con numpy, scipy y matplotlib. El texto insiste en que el código y las gráficas son herramientas de diagnóstico y no sustituyen revisar los supuestos; en modelos no convexos un optimizador puede quedarse en un óptimo local.

Unidades. Cinco unidades pendientes durante dos días son 10 unidades-día de faltante, mientras que cinco ventas perdidas son simplemente cinco unidades de demanda perdida. La probabilidad de agotarse, la tasa de surtido y la política de mínimo costo miden tres cosas distintas del servicio.

Monte Carlo. Para auditar el ejemplo Poisson(22) con S = 28, se simulan 200,000 demandas y se compara el costo promedio con el valor exacto (16.88). Por la ley de los grandes números ambos se acercan al crecer la muestra. El error estándar mide la variación de la simulación, no la duda sobre si la demanda realmente es Poisson.

Datos censurados. Si la demanda se estima con las ventas observadas, cuando se acaba la mercancía sólo se ve mín(N, S), no la demanda real. Tratar esas ventas como demanda completa **subestima el riesgo de faltante**.

10. Ejercicios resueltos

Resumo, paso a paso, las soluciones de los dos bloques de ejercicios de los apuntes.

10.1 Preguntas de la sección 5

1. EOQ y frecuencia (D = 18,000, K = 125, h = 5).

$$Q^* = \sqrt{\frac{2(125)(18{,}000)}{5}} = \sqrt{900{,}000} = 300\sqrt{10} \approx 948.68$$

$$\frac{D}{Q^*} \approx 18.97\ pedidos/año, \quad C^* = \sqrt{2(125)(18{,}000)(5)} \approx 4{,}743.42$$

Costo de pedir = costo de guardar = 2,371.71. No es correcto redondear a 19 pedidos y usar 18,000/19 como lote óptimo sin imponer explícitamente esa restricción.

2. Sensibilidad al faltante (D = 9,000, K = 100, h = 8). La fracción pendiente es h/(h + p):

p	Q*	B*	Fracción pendiente
8	670.82	335.41	1/2
80	497.49	45.23	1/11

Al subir p se tolera menos espera; cuando p → ∞, B* → 0 y Q* → √(2KD/h).

3. Fractil discreto (Poisson(14), $c_u = 12, c_o = 3$). La fracción es 12/15 = 4/5. Como F(16) = 0.7559 < 0.8 ≤ F(17) = 0.8272, **S* = 17**. Verifico: g(17) − g(16) = 15F(16) − 12 ≤ 0 y g(18) − g(17) = 15F(17) − 12 ≥ 0; el cambio de signo y las diferencias crecientes confirman el mínimo global.

4. Lotes enteros (D = 5,100, K = 70, h = 9). q_0 = 281.66; C(281) = 2,534.9626 y C(282) = 2,534.9574, así que **Q* = 282**, apenas arriba del mínimo continuo.

5. Producción (P = 25,000, D = 20,000). $I_{max} = (Q/25{,}000)(5{,}000) = Q/5$. Si P = D el inventario nunca crece, 1 − D/P = 0 y el lote "óptimo" se va a infinito; si P < D la demanda no se puede sostener.

6. Servicio estocástico ($\mu_d = 30, \sigma_d = 9$, L = 8). $\mu_L = 240, \sigma_L = 9\sqrt{8} \approx 25.456$; R(90 %) = 272.62 → 273 y R(99 %) = 299.22 → 300. Subir de 90 % a 99 % pide unas 27 unidades más de seguridad, sin que eso diga que 99 % sea económicamente óptimo.

7. Multiplicador. Las condiciones son $-K_iD_i/Q_i^2 + h_i/2 + \lambda c_i = 0$ para i = 1, 2 y $\lambda(c_1Q_1 + c_2Q_2 - M) = 0$. Si el presupuesto no alcanza, λ > 0; al crecer M, λ baja, y en el umbral sin restricción λ = 0.

8. Unidades del faltante. Si 5 clientes no son atendidos con cargo ℓ por venta perdida, cuesta 5ℓ de inmediato; si quedan pendientes 2 días con cargo anual p, cuesta 10p/365. Son mecanismos distintos.

10.2 Ejercicios adicionales

1. EOQ (D = 18,000, K = 125, h = 9, 360 días). $Q^* = \sqrt{500{,}000} = 500\sqrt{2} \approx 707.11$; 25.46 pedidos al año; ciclo de 14.14 días; costo de pedir = costo de guardar = 3,181.98 (total 6,363.96). Como C″(Q) > 0, es mínimo global.

2. Con faltantes (p = 36). h + p = 45 y hp = 324. Q* = 790.57, S* = 4/5Q* = 632.46, B* = 1/5Q* = 158.11; 12.65 días con inventario y 3.16 con faltante; costo 5,692.10, menor que 6,363.96 sin faltantes.

3. Distribución discreta. Con probabilidades 0.05, 0.15, 0.35, 0.30, 0.15 para demandas 0 a 4 y (c_u, c_o) = (8, 2), la fracción es 4/5:

S	0	1	2	3	4
F(S)	0.05	0.20	0.55	**0.85**	1.00
g(S)	18.80	11.30	5.30	**2.80**	3.30

El primer S con F(S) ≥ 0.8 es **S = 3**, que también tiene el menor costo.

4. Múltiplos de 50 (D = 12,000, K = 180, h = 6). Los vecinos de 848.53 son 800 (C = 5,100.00) y 850 (C = 5,091.18), así que el lote factible óptimo es **850**.

5. EPQ (P = 25,000, D = 10,000, K = 150, h = 4). 1 − D/P = 3/5; Q* = 1,118.03; producción 0.0447 años; ciclo 0.1118 años; inventario máximo 670.82; costo 2,683.28. El EOQ clásico usaría un área de inventario equivocada.

6. Punto de reorden ($\mu_d = 25, \sigma_d = 8$, L = 9). $\mu_L = 225, \sigma_L = 24$; R = 255.76, 264.48 y 280.83 para 90, 95 y 99 % (256, 265 y 281 enteros). La seguridad crece con $\sqrt{L}$ y no con L.

7. Dos productos (M = 8,000). Sin restricción Q = (500; 629.29) requiere 17,327.14, así que λ > 0. Con las dos expresiones de abajo y resolviendo $12Q_1 + 18Q_2 = 8{,}000$ queda λ ≈ 0.4944, $Q_1 \approx 224.62$ y $Q_2 \approx 294.70$:

$$Q_1(\lambda) = \sqrt{\frac{750{,}000}{3 + 24\lambda}}, \quad Q_2(\lambda) = \sqrt{\frac{1{,}980{,}000}{5 + 36\lambda}}, \quad 12Q_1 + 18Q_2 = 8{,}000$$

11. Resumen de modelos y comprobación

Modelo	Decisión	Regla óptima	Resultado del ejemplo
EOQ clásico	Q	$Q^* = \sqrt{(2KD/h)}$	$Q^* = 848.53$, $C = 5{,}091.17$
Pedidos pendientes	Q, S	$Q^* = \sqrt{(2KD(h+p)/(hp))}$	$Q^* = 948.68$, $C = 4{,}553.68$
Ventas perdidas	S	$F(S) \geq c_u/(c_u + h_o)$	$S^* = 28$
Lotes enteros	Q entero	Comparar $\lfloor q_0 \rfloor$ y $\lceil q_0 \rceil$	$Q^* = 849$
EPQ	Q	$Q^* = \sqrt{(2KD/(h(1 - D/P)))}$	$Q^* = 979.80$, $C = 4{,}409.08$
Newsvendor	q	$F(q^*) = c_u/(c_o + c_u)$	$q^* = 40$
Política (Q, R)	R	$R \approx L\mu + z\sigma\sqrt{L}$	$R = 258.85 \rightarrow 259$
Con presupuesto	$Q_1,\ldots,Q_n$	$Q_i = \sqrt{(2K_iD_i/(h_i + 2\lambda c_i))}$	$C = 20{,}268.00$

Antes de entregar cualquier resultado, yo aplicaría esta lista de comprobación:

1. Revisar que las unidades de tiempo de D, h y p sean compatibles.
2. Identificar si la demanda no surtida espera o se pierde, y elegir el modelo correcto.
3. Comprobar que la fórmula se cumple (por ejemplo, costo de pedir = costo de guardar en el EOQ).
4. Si la decisión debe ser entera o en múltiplos, comparar los candidatos factibles en lugar de redondear.
5. No confundir probabilidad de faltante, tasa de surtido y costo mínimo.
6. Verificar qué restricciones están activas y recalcular el costo directamente.

Conclusión

Después de leer los apuntes, me queda claro que la teoría de inventarios no es sólo aplicar una raíz cuadrada, sino un proceso completo: entender qué pasa con la demanda, definir qué se decide, armar la función de costo, encontrar el óptimo y, sobre todo, interpretar el resultado. Todos los modelos buscan el mismo equilibrio entre pedir poco y seguido o mucho y de golpe; lo que cambia de uno a otro son los supuestos.

Los ejemplos lo muestran bien: el EOQ clásico da un lote de 848.53 unidades con costo de 5,091.17; permitir pedidos pendientes baja el costo a 4,553.68, pero sólo si los clientes realmente esperan; producir gradualmente sube el lote a 979.80; y cuando la demanda es aleatoria el óptimo ya no es la media, sino el nivel que marca el fractil crítico entre el costo de faltar y el de sobrar.

Lo más valioso para mí es la advertencia que se repite de principio a fin: un resultado correcto en lo algebraico todavía tiene que tener sentido en la realidad. Por eso siempre hay que revisar unidades, distinguir entre medidas de servicio, verificar las restricciones y no redondear sin justificarlo.

Referencias

Nahmias, S. y Olsen, T. (2015). *Production and Operations Analysis* (7a ed.). Waveland Press.

Scarf, H. (1960). The optimality of (S, s) policies in the dynamic inventory problem. En *Mathematical Methods in the Social Sciences*. Stanford University Press.

Silver, E. A., Pyke, D. F. y Thomas, D. J. (2016). *Inventory and Production Management in Supply Chains* (4a ed.). CRC Press.

Zipkin, P. H. (2000). *Foundations of Inventory Management*. McGraw–Hill.